

2026년도 공공기관 용역과제
AI개발 수행내역서

과제명	AI 기반 비염 증상 예측 및 개인 맞춤형 케어 모델 개발
담당자	김 성 익

2026년 04월 03일

목차

- ① 프로젝트 개요
- ② 데이터 수집 및 전처리 과정
- ③ 탐색적 데이터 분석 (EDA)
- ④ K-Means 클러스터 모델
- ⑤ 클러스터링 일반화 검증 (Step 5)
- ⑥ LightGBM 일반화 검증(Step 6)
- ⑦ LSTM 시계열 모델 검토(Step 7)
- ⑧ 환경 API 실연동 점검
- ⑨ Streamlit 대시보드
- ⑩ 추가 보완 사항

피처명	설명	유형
has_asthma	천식 동반 여부 (0/1)	동반질환
has_atopic_derm	아토피 동반 여부 (0/1)	동반질환
has_food_allergy	식품 알레르기 동반 여부 (0/1)	동반질환
food_allergy_count	식품 알레르기 종류 수 (0~5)	동반질환
rhinitis_onset_age	비염 발병 나이 (세)	발병 특성
rhinitis_duration	비염 지속 기간 (년)	발병 특성
atopic_march	아토피 마치 진행 여부 (0/1)	발병 특성
is_female	성별 (여성=1)	인구통계
symptom_fhinorrhea	콧물 강도 (0~10, 합성)	증상 점수
symptom_congestion	코막힘 강도 (0~10, 합성)	증상 점수
symptom_sneezing	재채기/가려움 강도 (0~10, 합성)	증상 점수
symptom_ocular	눈 증상 강도 (0~10, 합성)	증상 점수

사업과제 : AI 기반 비염 증상 예측 및 개인 맞춤형 케어 모델 개발

1. 프로젝트 개요

본 프로젝트는 소아 알레르기 코호트 데이터를 기반으로 비염 환자를 동반 질환 특성에 따라 자동 분류하고, 맞춤형 가이드와 실시간 대기, 날씨 정보를 결합한 AI 기반 비염 케어 시스템을 구축합니다.

1.1 추진배경 및 목적

- 일상 질환 케어 공백 해소: 중증 질환 관리 서비스는 풍부하나, 비염과 같이 일상생활에 큰 불편함을 주는 경증 만성 질환 대상의 정밀 관리 서비스는 미비함.
- 데이터 기반 의사결정: 환자가 주관적 느낌에 의존해 약물을 오남용하지 않도록, 증상 데이터와 환경 데이터를 분석하여 객관적인 관리 지표를 제공하고자 함.
- 디지털 헬스케어 국산화: 해외 서비스(MASK-air)의 우수한 로직을 벤치마킹하여 국내 기상 환경 및 의료적 특성에 최적화된 모델을 구축함.
- 대규모 소아 알레르기 코호트 데이터를 분석하여 비염 환자의 임상적 공통점을 군집화(Clustering)하고, 사용자 맞춤형 관리 솔루션을 제공하는 AI 시스템을 구축함.

1.2 과제 범위

과제구분		내용
ML	데이터 범위 및 AI 기반 증상 클러스터링	Kaggle Childhood Allergies 코호트 데이터 (55,567명)
		Kaggle Healthcare 증상 프로파일 데이터 (858명)
		환자별 증상·동반질환 패턴을 분석하여 비염 유형(호흡기 알레르기형/ 비염+천식 복합형/ 아토피 마치형) 분류 모델 구현
	환경 요인 상관관계 분석	미세먼지, 꽃가루, 기온 등 외부 요인이 증상 악화에 미치는 영향 분석
	맞춤형 가이드 생성	분류된 유형과 실시간 환경 데이터를 결합한 개인별 행동 지침 도출
	프로토타입 구축	FastAPI 추론 서버 + Streamlit 대시보드 배포

2. 데이터 수집 및 전처리

2.1 사용 데이터셋

본 프로젝트는 두 가지 데이터셋을 활용했습니다. 주 데이터셋은 Kaggle Childhood Allergies 코호트(55,567명, 소아과 알레르기 진료 기록)입니다. 보조 데이터셋으로 Healthcare.csv(25,000행, 증상 텍스트 기반)를 EDA 참고용으로 활용했습니다.

출처	데이터셋	샘플 수	주요 컬럼	용도
Kaggle / Zenodo	Childhood Allergies cohort*	55,567	has_asthma, has_food_allergy, rhinitis_onset_age 등	메인 학습 데이터
Kaggle	Healthcare.csv (합성데이터)	25,000	Age, Gender, Symptoms, Disease	EDA 보조 참고

* cohort: 필라델피아 아동병원(CHOP, Children's Hospital of Philadelphia)의 케어 네트워크

2.2 전처리 파이프라인

src/data/preprocess.py의 handle_missing_values()와 remove_outliers_iqr()를 step1_feature_engineering.py와 step3_clustering.py에 연결해 실제 파이프라인에서 동작하도록 했습니다.

- 결측치 처리: 연속형 변수는 interpolate(선형 보간), 이진 변수는 0으로 채움
- 이상치 제거: IQR 기반 클리핑 (하한 $Q1 - 1.5 \times IQR$, 상한 $Q3 + 1.5 \times IQR$)
- 스케일링: StandardScaler (K-Means 거리 기반 알고리즘 적용)
- 피처 엔지니어링: 동반 질환 파생 변수 생성 (atopic_march, has_comorbidity)


단계	처리 내용	적용 함수
결측치 처리	연속형 피처(발병 나이, 지속 기간 등) 선형 보간(interploate)	handle_missing_values()
이상치 클리핑	$IQR \times 1.5$ 기준 상·하한 클리핑	remove_outliers_iqr()
표준화	StandardScaler 적용(클러스터링 직전)	StandardScaler.fit_transform()
데이터 병합	날짜 기준 증상 데이터 + 환경 데이터 Left join	merge_symptom_env()

3. 탐색적 데이터 분석 (EDA)

3.1 증상 변수 분포

Healthcare.csv 기반 증상 분포와 Childhood Allergies 코호트의 환경·임상 피쳐 분포를 분석하여 클러스터링에 활용할 핵심 피쳐를 선정했습니다.

증상별 VAS 점수 분포




[그림 1] 증상별 VAS 점수 분포(콧물, 코막힘, 재채기, 눈가려움)

3.2 환경 변수 분포

미세먼지(PM10, PM2.5), 기온, 습도, 꽃가루지수의 분포를 확인했습니다. PM10 평균 $45.4\mu\text{g}/\text{m}^3$, 습도 평균 55.0%, 꽃가루지수 평균 47.9로 국내 환경 특성이 반영되었습니다.

환경 변수 분포



[그림 2] 환경 변수 분포 (PM10, PM2.5, 기온, 습도, 꽃가루지수)

3.3 증상-환경 Person 상관관계 분석


히트맵 분석 결과, 천식 동반 여부, 식품 알레르기 동반 여부, 아토피 파치 세 변수가 상호 높은 양의 상관관계를 보이며 동반 질환 클러스터 분리의 핵심 피처로 확인됩니다.



[그림 3] 증상-환경 변수 상관관계 히트맵

3.4 시계열 증상 패턴

7일 이동평균 기준 월별 증상 점수 변화를 분석하였습니다. 봄(3~5월)과 가을(9~10월) 환절기에 꽃물, 재채기 점수가 급격히 상승하는 계절성 패턴이 뚜렷하게 나타났습니다.




[그림 4] 월별 평균 증상 점수 추이 (7일 이동평균, 2024년)

4. AI 분석 모델 구축 – K-Means 클러스터링

4.1 최적 K 선정


Elbow Method와 Silhouette Score를 동시에 분석하여 k=3을 최적으로 결정했습니다.

k=3에서 군집 내 응집도와 군집 간 분리도의 균형이 가장 우수했습니다.



[그림 5] 코호트 데이터 최적 클러스터 수 탐색 (Elbow + Silhouette)

Childhood Allergies - 최적 클러스터 수 탐색




[그림 6] 증상 데이터 기반 Elbow Method 및 Silhouette Score

※ k=3은 Silhouette 점수 기준 최고값(k=2) 보다 낮으나, 임상적으로 의미 있는 세 가지 비염 표현형을 명확하게 분리한다는 점에서 의료적 판단을 근거로 최종 채택하였습니다.


4.2 클러스터 프로파일

k=3으로 확정 후 전체 55,567명을 3개 동반 질환 기반 유형으로 분류했습니다.

유형 명	인원 (비율)	평균 발병	천식율	아토피율	식품 알레르기율	특징
호흡기 알레르기형	26,122 명 (47.0%)	7.9 세	0%	0%	18.6%	순수 비염, 동반질환 없음
비염+천식 복합형	22,342 명(40.2%)	7.0 세	100%	26.6%	0%	천식 100%, 호흡기 집중 관리 필요
아토피 마치형	7,103 명 (12.8%)	5.9 세	66.9%	44.4%	100%	식품 알레르기→아토피→비염→천식



[그림 7] 클러스터별 특성 프로파일



[그림 8] 클러스터별 발병 나이 분포

5. 클러스터링 일반화 성능 검증 (Step 5)

비지도 학습 모델의 신뢰성을 확보하기 위해 3가지 독립적 검증 방법을 적용했습니다. scipy/sklearn 미설치 환경에서도 동일한 결과를 재현할 수 있도록 순수 NumPy 기반으로 구현했습니다.

5.1 [A] 홀드아웃 분포 안정성 (80/20 분리)

클러스터	학습 비율	홀드아웃 비율	분포 드리프트
호흡기 알레르기형	0.128	0.128	0.0004
비염+천식 복합형	0.472	0.463	0.0090
아토피 마치형	0.400	0.409	0.0086

최대 드리프트: 0.0090 (< 5%) → 매우 안정 | 학습/홀드아웃 Silhouette: 0.2219 / 0.2238 (차이 0.0019)

5.2 [B] 다중 랜덤 시드 Silhouette (10개 시드)

10개 랜덤 시드(0, 7, 13, 21, 42, 55, 77, 88, 99, 123)에서 각 3,000명 샘플로 Silhouette를 계산했습니다.

평균: 0.2228 표준편차: 0.0030 범위: [0.2173, 0.2262] → 시드 변화에 매우 강건 (std < 0.01)

5.3 [C] Bootstrap Jaccard 복원추출 안정성 (50회)

5,000명 서브셋에서 Bootstrap 재샘플링 50회 반복 후 최적 헝가리안 매칭 기반 Jaccard 유사도를 측정했습니다.

평균 Jaccard: ≥ 0.85 → 클러스터 안정성 우수

5.4 검증 요약

검증 항목	결과값	기준	판정
[A] 홀드아웃 드리프트 (최대)	0.0090	< 5%	매우 안정
[A] Silhouette 학습/홀드아웃	0.2219 / 0.2238	차이 0.0019	일관성 우수
[B] 다중 시드 Silhouette	0.2228 $\pm$ 0.0030	std < 0.01	시드 강건
[C] Bootstrap Jaccard	≥ 0.85	-	구조 안정

Silhouette 점수 0.22는 이진형 동반 질환 피처의 유클리드 공간 특성상 중간값이지만, 드리프트와 Jaccard 안정성이 기준을 크게 상회하여 모델 신뢰성은 충분합니다.

6장. LightGBM 지도학습 분류기 (Step 6)

K-Means 클러스터 레이블을 의사 타겟(pseudo-target)으로 사용해 LightGBM 지도학습 분류기를 학습했습니다. 이를 통해 클러스터 구조가 **지도학습**으로 재현 가능한지 검증하고, 새 환자에 대해 보정된 확률 기반 예측을 제공합니다.

6.1 정밀도와 안전성에 초점을 둔 모델 설계


하이퍼파라미터	설정값
objective	multiclass (3 클래스)
n_estimators (학습 횟수)	500 (EarlyStopping patience=50)
learning_rate (학습률)	0.05
num_leaves	63 (기본값_31 보다 높게 설정하여 트리의 복잡도를 키움)
subsample	0.8 colsample_bytree: 0.8 (데이터의 피쳐 80%만 사용)
교차검증	StratifiedKFold 5-Fold (일반적인 Fold가 아닌 층화방식 사용)
학습 피쳐	has_asthma, has_atopic_derm, has_food_allergy, food_allergy_count, rhinitis_onset_age, rhinitis_duration, atopic_march, is_female (8개)

6.2 재현 성능 결과

5-Fold 교차검증 결과: Accuracy 1.0000 ± 0.0000 | Weighted F1 1.0000 ± 0.0000

완벽한 분류 성능은 동반 질환 기반 K-Means 클러스터가 임상적으로 매우 명확히 분리됨을 의미합니다. has_asthma, has_food_allergy, atopic_march 3개 피쳐가 클러스터를 거의 완벽하게 결정합니다.

LightGBM 분류기 — K-Means 클러스터 재현 성능



[그림 9] LightGBM 피쳐 중요도 및 혼동행렬

6.3 프로덕션 적용

redictor.py에 LightGBM 우선 / K-Means 폴백 이중 모델 구조를 구현했습니다. lgbm_rhinitis.pkl이 존재하면 predict_proba()로 보정된 확률을 제공하고, 없을 경우 기존 K-Means 거리 역수 softmax로 자동 폴백합니다. Streamlit 대시보드에는 LightGBM / K-Means 모델 타입 배지와 3개 클래스 확률 바 차트를 추가했습니다.

7장. LSTM 시계열 모델 검토 (Step 7)

비염 증상의 시간적 변화를 모델링하기 위해 LSTM을 검토했습니다. 현재 데이터셋(Childhood Allergies)은 정적 레코드 구조로 시간 축이 없어, AR(1) 자기회귀 프로세스 기반 합성 시계열($n=12,000$, $T=10$ 타임스텝)을 생성하여 학습했습니다.

7.1 LSTM 아키텍처

입력 형태: ($T=10$ 타임스텝, 4개 증상 피처) → LSTM(128) → Dropout(0.3) → BatchNorm → LSTM(64) → Dense(64, ReLU) → Dense(3, Softmax). Adam($lr=3e-4$), EarlyStopping(patience=15).

7.2 LightGBM vs LSTM 비교

비교 항목	LightGBM	LSTM
데이터 형태	정적 임상 피처 (8개)	합성 시계열 AR(1), $T=10$
예상 Accuracy	1.0000 (실제 달성)	0.80 ~ 0.90
예상 F1 (weighted)	1.0000 (실제 달성)	0.80 ~ 0.90
추론 속도	매우 빠름	상대적으로 느림
해석 가능성	피처 중요도 직접 제공	블랙박스 (SHAP 별도 필요)
실데이터 활용	현재 55,567명 그대로	종단 데이터 필요
프로덕션 적합성	즉시 배포 가능	실 시계열 확보 후 재학습

결론: LightGBM을 현 프로덕션 모델로 채택합니다. LSTM은 실제 환자별 종단 데이터(예: 주간 증상 기록)가 확보된 후 증상 진행 예측 모델로 활용할 계획입니다

8장. 환경 API 실연동 점검

8.1 구현 완료 항목

- 에어코리아 API: PM10, PM2.5, O3 실시간 수집 (TTL 60분 캐시)
- 기상청 API: 기온, 습도, 강수량 단기 예보 (TTL 60분 캐시)
- Tab 4 환경정보 탭: PM10 24시간 추이 차트 + 기온 예보 차트
- Tab 1 분석결과: 환경 데이터 연동 위험 메시지 (미세먼지·습도 임계치 기반)
- 11개 지역 측정소 선택 (서울 5개구 + 인천·수원·파주·대전·대구·부산)

8.2 누락 및 개선 필요 항목

항목	내용	우선순위
꽃가루 지수	미구현 - 환경부 꽃가루 위험지수 API 별도 연동 필요 (비염 핵심 유발 인자)	높음
O3 오존 경보	오존 데이터 표시만 됨, 임계치(0.06 ppm) 초과 시 경고 로직 없음	중간
CLUSTER_STATS 클러스터명	구 증상 기반 명칭 → 동반 질환 기반 신규 명칭으로 교체 완료	완료
risk_messages 유형 분기	구 클러스터명 참조 오류 → 신규 3유형 로직으로 교체 완료	완료
Healthcare데이터 병합오류	계획은 두 데이터를 AGE+GENDER 키로 병합해서 Healthcare.csv의 증상 텍스트(runny nose, sneezing 등)를 알레르기 코호트에 붙이는 것이었지만, Kaggle 알레르기 데이터의 컬럼이 Age, Gender가 아니라 GENDER_FACTOR, BIRTH_YEAR 형식이라 AGE/GENDER 키 자체를 만들지 못했고, KeyError로 병합이 실패	(임상 문헌 기반 합성값으로 대체, 모든 학습은 Zenodo 알레르기 코호트 데이터만 반영되었음)

9. Streamlit 대시보드

9.1 탭 구성

탭	주요 기능
Tab 1: 유형 분석	증상 슬라이더 입력 → LightGBM 예측 → 클래스 확률 바 차트 + 레이더 차트
Tab 2: 유형 현황	3개 유형 파이 차트 + 유형별 증상 강도 비교 바 차트
Tab 3: 유형 안내	각 유형 설명 + 관리 가이드 (CLUSTER_INFO 연동)
Tab 4: 환경 정보	에어코리아 PM10·PM2.5·O3 + 기상청 기온·습도·강수량 실시간 표시

9.2 LightGBM 연동 후 UI 변경 사항

- 결과 카드에 LightGBM / K-Means 모델 타입 배지 추가
- 3개 유형 클래스 확률을 수평 바 차트로 시각화 (유형별 고유 색상)
- LightGBM 활성 시 '실제 확률 기반 예측' 문구 표시
- K-Means 폴백 시 '비지도 학습 클러스터 거리 기반 예측' 문구 표시
- cluster_probs API 응답 필드 추가 (FastAPI ClusterResult 스키마 model_type 필드 포함)

10 향후 개선 과제

과제	설명	유형
꽃가루 지수 API 연동	환경부 꽃가루 위험지수 API → api_collector.py	미구현
O3 오존 경보 로직	오존 0.06 ppm 초과 시 경고 메시지 추가 (현재 수치 표시만)	미구현
is_female 입력 UI	LightGBM 8개 피쳐 중 is_female이 사이드바 미노출 → 기본값 0으로 처리 중. 성별 선택 UI 추가	미구현
LSTM 실 데이터 확보	환자별 주간 증상 기록 누적 시 LSTM 재학습으로 증상 진행 예측 가능. 현재는 AR(1) 합성 시계열 사용	계획
DSM 기반 증상 점수	현재 증상 피쳐는 VAS 0~10 슬라이더. 임상 분류(DSM/ARIA) 기반 구조화된 증상 점수체계로 고도화 필요	계획
모델 재학습 자동화	신규 예측 데이터가 DB에 1,000건 이상 쌓이면 step6를 자동 재실행하는 MLOps 파이프라인 구축	계획
API 인증/보안	FastAPI 엔드포인트에 JWT 인증 미적용. Streamlit Cloud 배포 시 보안 강화 필요	계획

부록 A. 데이터 디렉터리

본 부록은 모델 학습에 사용된 피처, API 입출력 스키마, 환경 데이터 컬럼의 정의 및 통계를 제공합니다.

A-1. 학습 데이터셋 컬럼 (소아 알레르기 건강 코호트 합성)

컬럼명	타입	범위/값	통계	설명
SUBJECT_ID	int	1 - N	고유 식별자	환자 고유 식별 번호
has_asthma	int	0 / 1	1=48.8%	천식 동반 여부 (0: 없음, 1: 있음)
has_atopic_derm	int	0 / 1	1=25.1%	아토피 피부염 동반 여부
has_food_allergy	int	0 / 1	1=12.8%	식품 알레르기 동반 여부
food_allergy_count	int	0 - 10	avg=0.2	식품 알레르기 항원 종류 수
rhinitis_onset_age	float	0 - 18 세	avg=7.3 SD=4.2	비염 최초 진단 나이 (세)
rhinitis_duration	float	0 - 18 년	avg=2.2 SD=2.9	비염 유병 기간 (년)
atopic_march	int	0 / 1	1=0.6%	아토피 마치 (아토피→천식→비염) 해당 여부
is_female	int	0 / 1	1=44.9%	성별 (0: 남, 1: 여)
cluster	int	0 / 1 / 2	K-Means 레이블	K-Means 군집 ID (LightGBM 학습 타겟)
cluster_label	str	3개 유형명	-	군집 ID에 대응하는 한글 유형명

A-2. API 입력 스키마 (PatientInput)

★ 표시 8개 필드는 LightGBM 예측 피처로 직접 사용됩니다. 증상 점수(symptom_*)는 대시보드 표시용이며 모델 예측에는 미사용입니다

필드명	타입	범위	기본값	LightGBM 피처	설명
has_asthma	int	0-1	-	★	천식 동반 여부
has_atopic_derm	int	0-1	-	★	아토피 피부염 동반 여부
has_food_allergy	int	0-1	-	★	식품 알레르기 동반 여부
food_allergy_count	int	0-10	0	★	식품 알레르기 항원 수
rhinitis_onset_age	float	≥ 0	-	★	비염 발병 나이 (세)
rhinitis_duration	float	≥ 0	0.0	★	비염 지속 기간 (년)
atopic_march	int	0-1	0	★	아토피 마치 해당 여부
is_female	int	0-1	-	★	성별 (0: 남, 1: 여)
symptom_rhinorrhea	int	0-10	0	-	콧물 증상 강도 (VAS 0-10)
symptom_congestion	int	0-10	0	-	코막힘 증상 강도
symptom_sneezing	int	0-10	0	-	재채기/가려움 강도
symptom_ocular	int	0-10	0	-	눈 가려움/충혈 강도

A-3. API 응답 스키마 (ClusterResult)

필드명	타입	예시 값	설명
cluster_id	int	1	군집 번호 (0 / 1 / 2)
cluster_label	str	비염+천식 복합형	예측 유형명
confidence	float	0.82	예측 신뢰도 (0-1). LightGBM: predict_proba 최대값; K-Means: 거리 역수 softmax 최대값
cluster_probs	dict[str,float]	{유형A:0.10,...}	3개 유형별 소속 확률 합계=1
description	str	천식 100% 동반...	유형 설명 텍스트
guide	list[str]	["흡입기...",...]	유형별 맞춤 관리 가이드 목록
model_type	str	lightgbm	사용된 모델 ('lightgbm' 또는 'kmeans')

A-4. 환경 데이터 컬럼 (실시간 API)

AirKorea(대기) + KMA(기상) API를 통해 60분 TTL 캐시로 수집됩니다. 꽃가루 지수(pollen_index)는 향후 환경부 API 연동 예정입니다.

컬럼명	출처 API	단위/범위	수집 주기	비고	설명
pm10	AirKorea	$\mu\text{g}/\text{m}^3 \geq 0$	60 min	실 연동	미세먼지 농도 (PM10)
pm25	AirKorea	$\mu\text{g}/\text{m}^3 \geq 0$	60 min	실 연동	초미세먼지 농도 (PM2.5)
ozone	AirKorea	ppm ≥ 0	60 min	실 연동	오존 농도 (O_3)
temperature	KMA	$^{\circ}\text{C}$	60 min	실 연동	기온
humidity	KMA	% 0-100	60 min	실 연동	상대 습도
precipitation	KMA	mm ≥ 0	60 min	실 연동	강수량
pollen_index	환경부	0 - 4 등급	일 1회	미구현	꽃가루 위험 등급 (0=없음 ~ 4=매우높음)

※ pollen_index는 현재 fetch_pollen() 함수 구현이 완료되지 않아 대시보드에서 '-' 로 표시됩니다.
환경부 꽃가루 위험지수 API 연동 후 활성화 예정입니다.